



GWE 2026 DATA SCIENCE CHALLENGE

Risk Prediction

Naufal Asa Malika 103012500151
Muhammad Zubair 102022500261




Problem Statement

Hipertensi adalah "pembunuh diam-diam" dan pemicu utama penyakit kardiovaskular.

Tujuan: Membangun model prediktif untuk deteksi dini risiko hipertensi sehingga intervensi medis/gaya hidup dapat dilakukan lebih cepat.

Figure 1. Prevalence of hypertension among adults aged 18 and over, by sex and age:
United States, 2017–2018




¹Significantly different from women within the same age group.

²Significant increasing trend by age.

NOTES: Hypertension is defined as systolic blood pressure greater than or equal to 130 mmHg or diastolic blood pressure greater than or equal to 80 mmHg, or currently taking medication to lower blood pressure. Estimates for age group 18 and over are age adjusted by the direct method to the U.S. Census 2000 population using age groups 18–39, 40–59, and 60 and over. Crude estimates are 48.2% for all persons, 52.5% for men, and 44.0% for women. Access data table for Figure 1 at:

<https://www.cdc.gov/nchs/data/databriefs/db364-tables-508.pdf#1>.

SOURCE: NCHS, National Health and Nutrition Examination Survey, 2017–2018.



Dataset


Source:

<https://www.kaggle.com/datasets/miadul/hypertension-risk-prediction-dataset>

Karakteristik Data: Memiliki 1.985 baris data rekam medis pasien.

Keseimbangan Data (Class Balance): Dataset sangat seimbang (Positif: 1032, Negatif: 953), sehingga model dapat belajar secara objektif tanpa bias.

Fitur Utama: Umur, BMI, Konsumsi Garam, Tingkat Stres, Kualitas Tidur, Riwayat Keluarga, dan Kebiasaan Merokok.



Metodologi

Alur Penelitian


Pengumpulan Dataset → Data Understanding → Data Cleaning & Preprocessing → Exploratory Data Analysis (EDA) → Feature Selection → Machine Learning (Random Forest) → Evaluasi Model → Deployment menggunakan Streamlit

Tahapan Penelitian


- Melakukan pembersihan dan persiapan data sebelum proses analisis.
- Melakukan Exploratory Data Analysis (EDA) untuk memahami pola dan hubungan antar variabel.
- Melatih model Random Forest untuk memprediksi risiko hipertensi.
- Mengevaluasi performa model menggunakan metrik klasifikasi.
- Mengimplementasikan model ke dalam aplikasi web berbasis Streamlit.

Hasil Analisis


Insight 1: Dari visualisasi Boxplot, kami menemukan outlier pada BMI (hingga angka 40+) dan Konsumsi Garam. Kami mempertahankan data ini karena ini adalah ekstrem fisiologis yang sangat mungkin terjadi di dunia nyata dan penting untuk prediksi.



Hasil Analisis




Insight 2: Semakin bertambah usia, risiko hipertensi cenderung meningkat.




Insight 3: Individu dengan nilai BMI yang lebih tinggi memiliki kecenderungan mengalami hipertensi.

Hasil Analisis




Insight 4: Riwayat hipertensi dalam keluarga berpengaruh terhadap kemungkinan seseorang mengalami hipertensi.




Insight 5: Kebiasaan merokok menunjukkan hubungan dengan peningkatan risiko hipertensi.

Hasil Analisis

Insight 6: Melalui Heatmap, kami mendeteksi tidak adanya masalah multicollinearity antar fitur (fitur saling independen), namun tetap memiliki korelasi matematis yang baik terhadap target utama (Hypertension).





Hasil Model


Algoritma yang Digunakan

- Random Forest Classifier


Hasil Evaluasi

- Accuracy : 96.73%
- Precision : 96-98%
- Recall : 96-97%
- F1-Score : 97%


Model Random Forest mampu memberikan performa yang baik dalam memprediksi risiko hipertensi berdasarkan data yang digunakan. Model yang telah dilatih kemudian disimpan menggunakan Joblib dan diintegrasikan ke dalam aplikasi Streamlit sehingga dapat digunakan untuk melakukan prediksi secara real-time.



Demo Aplikasi




Hasil aplikasi dari pengerjaan kelompok kita



Kesimpulan

Proyek ini berhasil membangun sistem prediksi risiko hipertensi menggunakan algoritma Random Forest berdasarkan data kesehatan dan gaya hidup pasien. Hasil Exploratory Data Analysis (EDA) menunjukkan bahwa faktor seperti usia, BMI, riwayat hipertensi dalam keluarga, dan kebiasaan merokok memiliki hubungan terhadap risiko hipertensi.

Model yang telah dibangun memiliki performa yang baik berdasarkan hasil evaluasi dan berhasil diimplementasikan ke dalam aplikasi web berbasis Streamlit sehingga dapat digunakan untuk melakukan prediksi secara interaktif.





**Thank
You**

